

论文 Review: Optimal Resizable Arrays

万字 (241880496)

2026年7月11日

论文标题	Optimal Resizable Arrays
作者	Robert E. Tarjan, Uri Zwick
发表信息	SOSA 2023 (Symposium on Simplicity in Algorithms), 2023
Review 作者	万字 (241880496)
日期	2026-07-11

目录

1	引言	2
2	基础知识	2
3	这篇文章讲了什么?	2
4	这篇文章的分层	3
5	背景和铺垫	3
5.1	问题定义	3
5.2	对前人工作的引用和论述	4
5.2.1	Two basic data structure	4
5.2.2	The data structure of Sitarski	4
5.2.3	The data structures of Brodnik et al.	5
5.3	The lower bound of Brodnik et al. and its extension	5
5.4	新方法的提出	6
5.4.1	一个简单的($O(N^{\frac{1}{3}})$, $O(N^{\frac{2}{3}})$)的实现	6
6	分工说明	6
7	参考文献	6

1 引言

简要介绍本文 Review 的背景、目的和结构安排。

2 基础知识

O 代表上界, Ω 代表下界.

均摊分析是用来分析某一特定操作的开销的分析方法, 比如分析数组插入元素带来的开销。

均摊分析有聚合分析、记账分析、势能分析三种。

聚合分析就是先把所有操作的开销加起来然后求平均。

记账分析是一种简化版的势能分析, 假设某一动作自身消耗为 n , 算的时候假设是 $m+n$, 即留 m 给别人, 最后看 m 是多还是少还是刚好, 调整 m 即可

势能分析类似于中学物理学的势能和动能, 就是说在考虑一个操作的时候不能只看它自己的开销还要关注它对之后操作的开销的影响。

举个例子, 假设一个vector采用超容则乘2复制的方法。那一个超容的插入的开销是 $O(n)$, 但它同时也便利了之后几次插入操作, 因为它们不必再重复扩容和复制的过程了。

这就好比小球沿着非光滑曲面冲上高处, 消耗动能产生摩擦热同时储存重力势能。

堆栈操作是一个很好的均摊分析的例子。

假设一个栈 s 支持三种操作, 开销如下:

push: $O(1)$; pop: $O(1)$; pop_k: $O(\min(s.size(), k))$;

聚合分析:

n 次push: $O(n)$

所有pop: $O(n)$

平均: $O(1)$

记账分析:

每一次push设代价为2, 留1

正好与pop抵消, 故为 $O(1)$

势能分析:

设一个势能函数 $\Phi(s)=s.size()$, 即将元素的数目看作资源

则push资源增加, 开销为2

pop资源减少, 开销为0

故为 $O(1)$

3 这篇文章讲了什么?

一共就讲了两个重点: 一是在给定的条件下给出了一种数组的实现, 使得访问代价为 $O(1)$ 且空间为 $N + O(N^{1/r})$, 这是他们的核心结论, 比之前的同方向的研究更好。

另一个是给定一个下界，说明你不可能做到一个数组的实现：在保持空间 $N + O(N^{1/r})$ 的同时还指望 grow 的时间小于 $\Omega(r)$ ，也就是让其他人别再试图往那个方向钻了。

4 这篇文章的分层

- 第一节：Introduction
- 第二节：问题定义
- 第三节：讲述前人的工作
- 第四节：关于一个有用的 lower bound
- 第五节：描述 $r = 3$ 时的 resize 和 store 开销
- 第六节：扩展至任意 $r \geq 2$ 的情况
- 第七节：对第六节中的方法的一个小瑕疵进行优化
- 第八节：提出抽象增长游戏（一个抽象的数学模型）
- 第九节：用抽象增长游戏证明在空间为 $N + O(N^{1/r})$ 时他们的实现是最优的

接下来的 review 我会按照原文的结构分成四个部分：

背景和铺垫：1-4

提出新方法：5-7

证明无法更牛逼：8-9

我自己的一些思考

5 背景和铺垫

5.1 问题定义

这篇文章讨论的问题不包括在 array 中间加或改元素的情况。

他们还假设了他们的系统里可以使用类似于 free 和 malloc 这样的工具来分配和释放任意位置和大小空间且这种操作对每个单位的代价是常数级的。也就是说，他们不管内存管理系统的实现，默认它已经足够好了。然后他们介绍了一种叫做 block 的东西，他们令一个可变数组由若干定长数组的组合来实现的。这篇文章讨论的所有数据结构本质上都是 blocks。这是一个值得注意的地方，因为所有主流编程语言的可变数组都是由连续内存空间来实现的而不是用所谓的 block。实际上我之前从来没听过 block 这种设计。block 一共可分为三种：数据 block：直接存目标数据，索引 block：存指向其它 block 的指针和辅助 (auxiliary) block：存一些别的。这有点类似于操作系统中的分页内存管理机制中的页表和数据块和辅助位。

而这种分类是何意味呢？这主要是为了引出他们自己给出的一个丈量即：Definition 2.1($(s(N), t(N))$ -implementation). Let $s(N), t(N)$ be two non-decreasing functions. A resizable array data structure is said to be an $(s(N), t(N))$ -implementation if it uses at most $N + s(N)$ space to store an array of size N , and at most $N + t(N)$ space during a grow or shrink operation on an array of size N . 这个定义几乎贯穿全文也是本文最大的创新。即将一个可变数组的空间消耗分两种情况来看一种是增或减时的开销以及其它时候的开销。也就是他们敏锐的捕捉到了一个可变数组的开销不是一成不变的，这里面有可以操作的空间。而之前的所有研究者都没有抓住这一点。

5.2 对前人工作的引用和论述

5.2.1 Two basic data structure

一共讲了两种基本的数据结构，第一种是最蠢的，用一个 N 空间的定长数组来模拟一个可变数组，每一次删除或增加元素都要重新分配空间然后完成复制。这几乎没有意义，作者写它估计是为了水字数。第二种是用得最广的即 geometric expansion/shrinking 结构，就是我们最熟悉的C++的vector的实现。均摊分析算下来grow 的代价为 $(1+1/a)$, shrink的代价为 $(1/a)$ 。这个结构已经不错了，也非常practical。

5.2.2 The data structure of Sitarski




Figure 1: Sitarski's HAT data structure.

Sitarski的实现名字叫hashed array tree(HAT)。名字很高级但实际上既没有哈希也没有树。它本质上就是数组套数组，还是页表那一套。它就是把一个数组切成小块每一个block大小为 B ，然后再来一个索引块，也为 B ，所有块大小都是 B 。找元素的时候就查两次数组就好了。它的优势在于每次超容的时候只要加一个索引指向一直被维护的空数据block即可。但其实它复杂度和geometric差不多。总的来说这还是一种很简单的很容易想到的实现。下一个实现就是它的变形。

5.2.3 The data structures of Brodник et al.

这个比较有意思，这个实现的美妙之处是 no rebuild is necessary and data items do not need moving。它的实现思路和上一个类似。都是先查指针再插数据块。但不同之处在于每个数据块大小不一且呈现递增趋势。之前Sitariski的做法的缺点在于当N越来越大，B由于要满足单次查询 $O(1)$ 的条件而不得不扩大，这一扩大，就要重建和搬元素。但是Brodnik的做法却不同，由于B自动增大，假设按1,2,3,4,.....n这个顺序来,最后的B和N的关系刚好是 $B = \sqrt{2N}$ 。但复杂度和前两种差不多，依旧是 $N + O(\sqrt{N})$ 。作者之后拿这个算法开刀来展开他的理论

5.3 The lower bound of Brodник et al. and its extension

前面已经引出了Brodnik的实现，接下来提出了三个结论如下：

定理 5.1. *Any data structure for maintaining a resizable array must at certain times use $N + \Omega(\sqrt{N})$ space, where N is the current length of the array, even if only grow and access operations are performed.*

定理 5.2. *Any $(s(N), t(N))$ -implementation of resizable arrays must have $s(N) \cdot t(N) \geq N$, even if only grow and access operations are supported.*

定理 5.3. *For any integer $r \geq 1$, any data structure that uses only $N + O(N^{1/r})$ space for storing a resizable array of size N must occasionally use $N + \Omega(N^{1-1/r})$ space during a grow operation, even if only grow and access operations are performed.*

我来展开说明。

首先，需要注意，这里所有的结论都是针对Brodnik的实现。有一个关键点在于这种实现下,Block的大小是递增的。

1. Theorem 4.1 说明：这个定理是说一个数组在扩容的时候，总有那么一个时刻，假设这个时刻它的元素的数目为 N ，那么此时它所需要的空间为 $N + \Omega(\sqrt{N})$ 。证明也很简单，显然随着N：数组元素的增加，k:索引Block的数量的增加是跳跃式的，即一个数组可能在两个时刻k相同但是Block的数目差距很大。显然所有的数据块都是必须的，这一部分开销为N，而索引块的容量比较复杂，因为是跳跃性的增加的。所以分类讨论。当 $k \geq \sqrt{N}$ 时，空间消耗为 $N + \Omega(\sqrt{N})$ 。但这只是极少数情况时k的取值，实际上k常常小于 $\sqrt{N}$ 因为现有的索引块指向的数据块不被装满才是常态。当k小于 $\sqrt{N}$ 时,平均下来每个数据块的大小必然大于 $\sqrt{N}$ ，根据鸽巢原理，必然存在一个数据块，它的大小大于 $\sqrt{N}$ 。回看这个大的数据块刚刚被分配的时候也就是它里面还是空的时候，假设此时数据块的总容量为 N' 显然此时的空间消耗为 $N' + \Omega(\sqrt{N'})$ （这里我们甚至没考虑指针的开销）。证明完毕。

2. Theorem 4.2 说明：这个的证明其实和上面的4.1类似。首先重申一遍 $s(N)$ 和 $t(N)$ 的定义。 $s(N)$ 表示在任何时候存储一个大小为 N 的可变数组所需的最多空间， $t(N)$ 表示在增长或缩小操作期间使用的最多空间。我们依旧只讨论除存数据的空间以外的开销。

只要关注索引块和数据块和空白块的相对变化就好了。当空白块为空的时候所有的额外开销都用于储存索引，此时索引的数量就是 $s(N)$ (有个前提，索引项的大小是一个字，而以上我们所有的讨论都是以字为单位，忘了说了哈哈)。那么根据鸽巢原理，必然存在一个数据块，它的大小 $\geq \frac{N}{s(N)}$ 。那么我们再回到这个大块被创建的时候还是空的时候，设此时的元素数目为 N' ，显然此时的开销为 $N' + \frac{N}{s(N)} + \text{else}$ 。所以 $t(N') \geq \frac{N}{s(N)}$ ，回到元素数目为 N 的时候，由于 $t(N) \geq t(N')$ ，所以 $t(N) \geq \frac{N}{s(N)}$ 。所以 $s(N) \cdot t(N) \geq N$ 。证毕。

3. Corollary 4.3 说明：这就是从上一个结论导出来的必然结果， $\frac{1}{r}$ 只是一个人为选定的参数，不用纠结。

5.4 新方法的提出

5.4.1 一个简单的($O(N^{\frac{1}{3}}), O(N^{\frac{2}{3}})$)的实现

这是一个承上其下的部分，通过之前的介绍，作者提出了一个简单的实现，满足空间为 $N + O(N^{1/3})$ ，增长操作的开销为 $O(N^{2/3})$ 。

这个实现的思路是这样的：

6 分工说明

本项目所有工作由同一人独立完成。包括：

- 论文选题与精读
- 文献检索与综述
- Review 正文撰写
- 个人反思写作
- 项目管理与版本控制

AI 工具（GitHub Copilot / ChatGPT 等）的使用记录见 `records/ai-usage.md`。

7 参考文献

详见 `references/bibliography.md`。